



# UNIVERSIDAD DE GRANADA

## TRABAJO FIN DE GRADO

INGENIERÍA INFORMÁTICA

### Aprendizaje Automático para la extracción de características y detección de situaciones anómalas en multitudes

---

#### Autor

Diego Navarro Cabrera

#### Directores

Name of the main supervisor

Name of the second supervisor (if available)



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA INFORMÁTICA Y  
TELECOMUNICACIONES

—  
Granada, 25 de abril de 2021

# **Aprendizaje Automático para la extracción de características y detección de situaciones anómalas en multitudes**

Diego Navarro Cabrera

**Palabras clave:**

**Resumen**

**Machine learning for feature extraction and abnormal crowd behavior**

Diego Navarro Cabrera

**Keywords:**

**Abstract**

---

Yo, **Diego Navarro Cabrera**, alumno del Grado de Ingeniería Informática de la **Escuela Técnica Superior de Ingeniería Informática y Telecomunicaciones de la Universidad de Granada**, con DNI 75935043Z, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Grado en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

A handwritten signature in blue ink, appearing to read "Diego", enclosed within a roughly oval-shaped outline.

Fdo: Diego Navarro Cabrera

Granada, 25 de abril de 2021

---

**D. Name of the main supervisor y D.<sup>a</sup> Name of the second supervisor (if available)**, profesores del Departamento de Ciencias de la Computación e Inteligencia Artificial de la Universidad de Granada.

**Informan:**

Que el presente trabajo, titulado *Aprendizaje Automático para la extracción de características y detección de situaciones anómalas en multitudes*, ha sido realizado bajo su supervisión por **Diego Navarro Cabrera**, y autorizamos la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expiden y firman el presente informe en Granada a 25 de abril de 2021

**Los directores:**



**Name of the main supervisor**



**Name of the second supervisor  
(if available)**

## **Agradecimientos**

---

# Índice general

---

<b>Índice general</b>	<b>5</b>
<b>1 Introducción</b>	<b>6</b>
<b>2 Fundamentación Teórica</b>	<b>7</b>
2.1. Aprendizaje automático . . . . .	7
2.2. Máquina de soporte vectorial . . . . .	7
2.3. Extracción de características . . . . .	7
2.4. Autoencoders . . . . .	7
2.5. Aprendizaje multi-tarea . . . . .	7
<b>3 Descripción del problema</b>	<b>8</b>
3.1. Conjuntos de datos de trabajo . . . . .	8
3.1.1. UMN Crowd Dataset . . . . .	9
3.1.2. Violent Flows . . . . .	10
3.2. Estado del arte . . . . .	11
3.2.1. Modelo basado en descriptores visuales locales de nivel medio . . . . .	11
3.3. Modelo propuesto . . . . .	12
<b>4 Resultados experimentales</b>	<b>13</b>
4.1. Metodología usada . . . . .	13
4.1.1. UMN Crowd Dataset . . . . .	13
4.1.2. Violent Flows . . . . .	13
4.2. Comparación de resultados . . . . .	13
4.2.1. UMN Crowd Dataset . . . . .	13
4.2.2. Violent Flows . . . . .	13
<b>5 Conclusión</b>	<b>14</b>
<b>Bibliografía</b>	<b>15</b>

# 1 Introducción

---

Intro

# Fundamentación Teórica

---

- 2.1. Aprendizaje automático
- 2.2. Máquina de soporte vectorial
- 2.3. Extracción de características
- 2.4. Autoencoders
- 2.5. Aprendizaje multi-tarea

# Descripción del problema

---

En este capítulo desarrollaremos en más profundidad el problema a tratar. Como ya hemos mencionado anteriormente, nuestro objetivo es estudiar el comportamiento de una multitud para detectar cuándo se está produciendo una anomalía.

En concreto nos centraremos en el enfoque holístico o *top-down* de este problema. Este enfoque trata a la multitud como un solo ente y analiza la dinámica del grupo más que las acciones de sus individuos. La detección de comportamientos individuales anómalos dentro de la multitud queda fuera del ámbito de este trabajo, pero algunas propuestas de las estudiadas podrían adaptarse para ello.

La estructura de esta sección será la siguiente. Primero hablaremos de los conjuntos de datos sobre los que trabajaremos. A continuación trataremos el estado del arte y explicaremos en más profundidad el modelo sobre el que nos hemos basado. Finalmente detallaremos el modelo desarrollado y diversas alternativas que se han tenido en cuenta

## 3.1. Conjuntos de datos de trabajo

Se han elegido 2 conjuntos de datos ampliamente usados en el ámbito de la detección de anomalías en multitudes. El primero es el UMN Crowd Dataset [1], que consiste de una pequeña selección de vídeos en el que un grupo de personas echa a correr tras una señal. El segundo dataset es conocido como Violent Flows [2] y recoge una mezcla de vídeos de peleas y vídeos de control. Estos dos conjuntos de datos nos permitirán comprobar la efectividad del modelo ante 2 de las anomalías más habituales y relevantes en el día a día: las peleas y escenarios de pánico. Además su amplio uso en la literatura nos permitirá comparar fielmente nuestro modelo con otros muchos . A continuación describiremos más detalladamente ambos conjuntos.

### 3.1.1. UMN Crowd Dataset

Este conjunto de datos, elaborado por la Universidad de Minnesota (UMN), consiste de 11 vídeos en los que un grupo de personas se comporta de manera normal hasta que recibe una señal y todos se dispersan corriendo. Los 11 vídeos se dividen en 3 escenas distintas, cada una con 2, 6 y 3 vídeos respectivamente. Todos estos vídeos se encuentran unidos en un mismo archivo que conviene dividir antes de ser procesado.



Figura 3.1: Ejemplo de fotograma normal (izqda) y anómalo (drcha) en la escena 1.

Este dataset clasifica los fotogramas normales y los anómalos por medio de un cartel que aparece en pantalla cuando se produce la anomalía, tal y como se puede ver en 3.1. Para evitar que esto pueda influir en nuestro modelo se ha recortado la parte superior de cada vídeo para eliminar dicho cartel. Por otro lado, tal y como se detalla en [3] estos carteles no son exactos, ya que aparecen significativamente después del comienzo de la anomalía. Es por esto que se ha decidido usar las anotaciones provistas en dicho artículo para etiquetar el comienzo de la anomalía en cada vídeo. Además de esto, en la mayoría de los casos la anomalía acaba antes de que empiece el siguiente vídeo, por lo que también tendremos que anotar el fotograma de finalización de cada caso. Hablaremos con más detalle de esto en el apartado de experimentación.

A pesar de sus ventajas y su uso muy extendido, este dataset presenta algunos inconvenientes que hay que tener en cuenta. Para empezar, su tamaño de 11 vídeos es bastante limitado, más aún si tenemos en cuenta que están divididos en 3 escenas que han de evaluarse de manera separada. Además solo representa anomalías de un tipo muy específico (gente echando a correr), por lo que no nos sirve para evaluar modelos enfocados a detectar todo tipo de

anomalías, algo de lo que hablaremos cuando propongamos nuestro modelo.

### 3.1.2. Violent Flows

Este conjunto de datos es una colección de vídeos de escenas reales para entrenar y evaluar modelos de detección de violencia. Contiene 246 instancias que se dividen en vídeos con violencia y sin ella. Se tratan de escenas cortas de entre 1 y 6 segundos y que se clasifican de manera íntegra como violentas o no.



Figura 3.2: Fotograma de ejemplo de una escena normal (izqda) y una violenta (drcha)

Los vídeos de este conjunto han sido extraídos de YouTube, y son muy distintos entre si, lo que nos permitirá comprobar la capacidad de generalización de nuestro programa. Por otro lado, la baja resolución a la que se encuentran dificulta su análisis, ya que algunos fotogramas están tan borrosos que es difícil saber qué está pasando.

De forma similar al conjunto de datos anterior, este posee una cantidad de instancias de entrenamiento bastante limitada (246 vídeos clasificados individualmente), y se centra en un tipo de anomalías concreto, en este caso las peleas. Por otro lado, al contrario de lo que cabría esperar al trabajar con anomalías, ambas clases tienen un número de instancias muy equilibrado, 121 vídeos violentos y 125 normales, lo que nos podría facilitar el entrenamiento de un modelo de clasificación binaria, pero dificultar el uso de otras opciones centradas en entrenar únicamente con instancias normales (clasificadores de una sola clase).

### 3.2. Estado del arte

#### 3.2.1. Modelo basado en descriptores visuales locales de nivel medio

El modelo sobre el que vamos a basar nuestra propuesta es el expuesto en [4]. Este artículo propone un proceso analítico de extracción de características, que se realiza a partir de una representación espacio-temporal de la multitud. Esta representación está formada por un conjunto de puntos de interés extraídos por un algoritmo de detección como FAST o SIFT.

Los puntos son rastreados a lo largo del tiempo, guardando las trayectorias que siguen, representando así la información temporal del modelo. Para hacer esto se usa un rastreador de características dispersas como ROLF o el rastreador de Kanade–Lucas–Tomasi.

Para representar la información espacial, cada punto está relacionado con sus vecinos por medio de una triangulación de Delaunay. Dicha triangulación es una red de triángulos conexa y convexa en donde la circunferencia circunscrita de cada triángulo no contiene ningún vértice de otro triángulo. También podría usarse un algoritmo de los K vecinos más cercanos, pero el artículo sostiene que el grafo aporta una mejor representación de la información local y espacial.




Figura 3.3: Ejemplo extraido de [4]. (a) Fotograma de ejemplo. (b) Detección de puntos de interés con FAST. (c) Trayectorias de los puntos a lo largo del tiempo. (d) Triangulación de Delaunay.

### **3.3. Modelo propuesto**

# **Resultados experimentales**

**4**

---

## **4.1. Metodología usada**

### **4.1.1. UMN Crowd Dataset**

### **4.1.2. Violent Flows**

## **4.2. Comparación de resultados**

### **4.2.1. UMN Crowd Dataset**

### **4.2.2. Violent Flows**

# 5 Conclusión

---

Conclusión

## Bibliografía

---

- [1] UMN Crowd Dataset. [http://mha.cs.umn.edu/proj\\_events.shtml#crowd/](http://mha.cs.umn.edu/proj_events.shtml#crowd/).
- [2] Violent Flows Dataset. <https://www.openu.ac.il/home/hassner/data/violentflows/>.
- [3] Duan-Yu Chen y Po-Chung Huang. “Motion-based unusual event detection in human crowds”. En: *J. Visual Communication and Image Representation* 22 (feb. de 2011), págs. 178-186. doi: [10.1016/j.jvcir.2010.12.004](https://doi.org/10.1016/j.jvcir.2010.12.004).
- [4] Hajar Fradi, Bertrand Luvison y Quoc-Cuong Pham. “Crowd Behavior Analysis Using Local Mid-Level Visual Descriptors”. En: *IEEE Transactions on Circuits and Systems for Video Technology* PP (oct. de 2016), págs. 1-1. doi: [10.1109/TCSVT.2016.2615443](https://doi.org/10.1109/TCSVT.2016.2615443).